

Detección de multitudes enfocado en el sistema de Transmilenio

Nicolas Palacios, Jhon Piñeros, Juan Carlos Baez,
Juan David Martínez, Diego Leon

Septiembre 2022

1 Abstract

Mobility in the city of Bogota is an issue that for many people becomes a problem in their daily lives, especially if they use Transmilenio as their main transportation system, that is why the approach we want to give to the development of this project is the use of artificial intelligence in this service of transportation and how it can become more efficient and at the same time make people feel comfortable when using it

2 Introducción

La movilidad en la ciudad de Bogotá es un tema que para muchas personas se convierte en un problema de su diario vivir, sobre todo si se movilizan en el sistema de transporte Transmilenio, por lo que, el enfoque que le queremos dar al desarrollo de este proyecto es el uso de la inteligencia artificial en la detección de multitudes en dicho medio de transporte, como se puede volver más eficiente y que las personas se sientan más cómodas al utilizarlo.

3 Descripción y caracterización del problema

Bogotá es la ciudad más grande de Colombia y una de las más grandes de Latinoamérica, y a pesar de esto no cuenta con la infraestructura necesaria

para garantizar una normal movilidad dentro de la ciudad. Adicionalmente, según INRIX [1] es la peor movilidad a nivel nacional y la octava peor a nivel internacional generando mucho malestar para todos quienes están en la ciudad.

Para intentar solucionar esta problemática, se intentó implementar un sistema de transporte público masivo, el cual no logra solucionar correctamente el problema de movilidad. Las personas tardan en promedio 51 minutos dentro del tráfico, quienes usan transporte público, que son más de 4 millones de personas diarias, suelen esperar en promedio 20 minutos en la parada de SITP/Transmilenio retrasando por completo el día a día y productividad de millones de colombianos [Figura 1 y 2].

El sistema Transmilenio usa la ley de oferta y demanda para determinar cómo enviar las diferentes rutas. En las figuras 3 y 4 encontramos los cálculos de las entradas a las estaciones en horas pico de la mañana y de la tarde, sin embargo, midiendo las entradas a las estaciones, situación que puede resultar con un sesgo grande debido a los transbordos de ruta y la falta de especificación de que ruta es a la que están accediendo los usuarios. [3]

Además de la mejora para ver esta demanda, otra ventaja de un modelo de reconocimiento a partir de inteligencia artificial es que disminuiríamos ese intervalo de tiempo de 15 min, a un segundo o menos.

Si hablamos de la frecuencia de autobuses, está la calculan a partir del modelo de la figura 5, donde a partir de la recolección de datos pueden dar con una frecuencia óptima para el sistema de transporte, teniendo en cuenta esto, lo que nuestra iniciativa buscará es aumentar la precisión en la ocupación estimada, para mejorar la oferta programada.

¿Cuánto tiempo suele esperar la gente en una parada en Bogotá todos los días?

El Promedio de tiempo que la gente en Bogotá espera en una parada o estación para su línea de SITP, Transmilenio & Funicular en un día laborable es 19 min.




Figure 1: Tiempo promedio de espera en las principales ciudades de Colombia [2]

¿Cuántas personas en Bogotá suelen esperar mucho tiempo en una parada?

El Porcentaje de personas en Bogotá que esperan más de 20 minutos en promedio a su línea de transporte público, todos los días, por ejemplo hacia y desde el trabajo es 56%.




Figure 2: Porcentaje de personas que esperan más de 20 minutos en las principales ciudades de Colombia [2]

Ilustración 24: Comportamiento demanda hora pico de la mañana cada 15 minutos




Figure 3: Fuente: TRANSMILENIO S.A. - Análisis Propio,2018

Ilustración 25: Comportamiento demanda hora pico de la tarde cada 15 minutos




Figure 4: Fuente: TRANSMILENIO S.A. - Análisis Propio,2018




Figure 5: Fuente: Enrique Cuartas - Factores para definir tiempos de salida de los buses, 2018

4 Objetivos

4.1 Objetivo Especifico

Realizar el estudio donde veamos la factibilidad de la Inteligencia Artificial para la detección de multitudes en el Transmilenio.

4.2 Objetivos Especificos

- Realizar investigación acerca de la inteligencia artificial (IA) para el reconocimiento de un número de personas dadas las imágenes para poder utilizar está en la recolección de tiempo real a partir de las cámaras de las estaciones o buses.
- Estudio de una posible infraestructura para la recolección en tiempo real.
- Realizar pruebas con videos de un flujo de personas abundante y determinar si se está cumpliendo lo propuesto en el Paper.

5 Marco teórico

5.1 Machine Learning

También conocido como aprendizaje automático es una forma de Inteligencia Artificial (IA) que permite a la máquina identificar patrones en los datos recopilados. Así, logra aprender de forma autónoma a realizar una

tarea, hacer predicciones o mejorar el rendimiento en la ejecución de la tarea. [4]

5.2 Inteligencia Artificial

Es un subcampo de la informática que mediante la combinación de algoritmos tiene el objetivo de crear máquinas que puedan realizar las mismas tareas que el ser humano y que cuenten con las mismas capacidades. [5]

5.3 Big data

Hace referencia a los datos que contienen una mayor variedad y se presentan en volúmenes crecientes y a una velocidad alta. Por lo que, está formada de conjuntos de datos de gran tamaño y complejidad. [6]

5.4 Amazon Rekognition

Amazon Rekognition ofrece capacidades de visión artificial (CV) previamente entrenadas y personalizables para extraer información a partir de las imágenes y los videos. Analice millones de imágenes, streaming y videos almacenados en segundos y aumente las tareas de revisión humana con inteligencia artificial.[7]

5.5 Amazon S3

Es un servicio de almacenamiento de objetos que ofrece escalabilidad, disponibilidad de datos, seguridad y rendimiento líderes en el sector. Clientes de todos los tamaños y sectores pueden almacenar y proteger cualquier cantidad de datos para prácticamente cualquier caso de uso, como los lagos de datos, las aplicaciones nativas en la nube y las aplicaciones móviles.[8]

5.6 Amazon Kinesis Video Stream

Amazon Kinesis Video Streams facilita la transmisión segura de videos desde dispositivos conectados a AWS para tareas de análisis, aprendizaje automático (ML), reproducción y otros procesos. Kinesis Video Streams aprovisiona automáticamente y escala de manera elástica toda la infraestructura necesaria para incorporar datos de las transmisiones de vídeo de millones de dispositivos.[9]

5.7 Amazon Lambda

Lambda es un servicio informático que permite ejecutar código sin aprovisionar ni administrar servidores.

6 Estado del arte

En este apartado haremos la revisión de las investigaciones llevadas a cabo previamente con respecto al uso de la detección de multitudes, tanto en un ámbito nacional como internacional.

La empresa Alstom es la primera que encontramos, usando esta detección para integrarla a los distintos servicios de transporte, esta, según afirma el diario el País, ha desarrollado un optimizador de tráfico multimodal o, lo que es lo mismo, un software inteligente que reúne información de trenes, tranvías, autobuses y sistemas de bicicletas compartidas, la analiza y propone soluciones eficientes de adaptación y reorganización urbana en tiempo real. [11]

Otra empresa que genera este software para la detección de multitudes es Senstar, la cual, está dirigida para la seguridad pública o privada, también para que las empresas que estén interesadas en publicitar un producto en los distintos lugares públicos, entre sus distintas ventajas, se evidencian que esta sirve a tiempo real, que a pesar de las distintas dificultades meteorológicas es capaz de realizar esta detección. [12]

Amazon Rekognition Video es una herramienta de amazon reconocida, la cual el mismo amazon la define como, Amazon Rekognition facilita la incorporación del análisis de imagen y vídeo a sus aplicaciones. Proporcione una imagen o un vídeo a la API de Amazon Rekognition y el servicio podrá identificar objetos, personas, texto, escenas y actividades. Asimismo, puede detectar cualquier contenido inadecuado. Amazon Rekognition proporciona además funcionalidades de análisis, comparación y búsqueda de rostros altamente precisas. Puede detectar, analizar y comparar rostros para una amplia variedad de casos de uso, como la verificación de usuarios, catalogación, contabilización de personas y seguridad pública. [13]

7 Propuesta Solución

Nuestra propuesta de solución para la problemática expuesta anteriormente consiste en utilizar las cámaras establecidas en cada estación de Transmilenio y a través de la herramienta explicada de amazon anteriormente, contar las personas que se encuentran en la puerta de cada ruta.

Es decir, se mantendrá la forma común del cálculo de Transmilenio, añadiéndole la detección de nuestro sistema de machine learning el cual, será más certero en la información para estos cálculos y a su vez podrá funcionar en tiempo real para detectar cualquier anomalía.

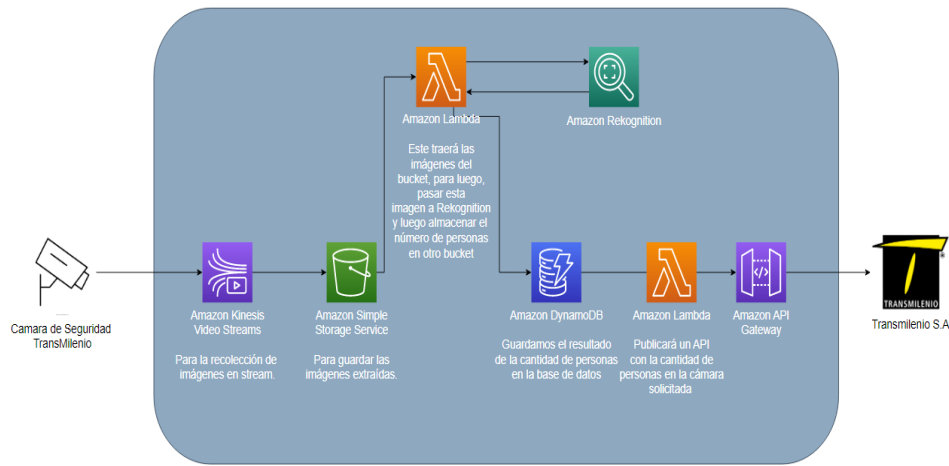


Figure 6: Arquitectura de la solución en AWS

Para realizar esto, contaremos con la arquitectura en AWS de la figura 3.

La cual consistirá en traer los streamings de las cámaras, luego con ayuda de Kinesis Video Stream, extraer las imágenes por segundo, para luego, guardarlas en un Bucket, el cual servirá como insumo para un Lambda el cual detectará cuando una imagen sea guardada en el Bucket y a esta la pasará al Amazon Rekognition. Una vez esté la imagen procesada, se guardará en una base de datos DynamoDB para luego hacer un api con un lambda y publicarlo con ayuda de Amazon API Gateway, el cual será accesible por la empresa Transmilenio S.A.

8 Evaluación

La evaluación de este prototipo consistirá en hacer fotos a grandes multitudes, para corroborar la precisión de este modelo, en cuanto a la cantidad de personas que hay realmente.

Para ello haremos uso del modelo presentado [Figura 7]. La idea de este es traer las imágenes de un bucket para luego procesarlas y dar un número de personas en la foto, con esto comprobar la eficiencia a través de unas fotos de prueba, asimilando la imagen de una cámara de Transmilenio.

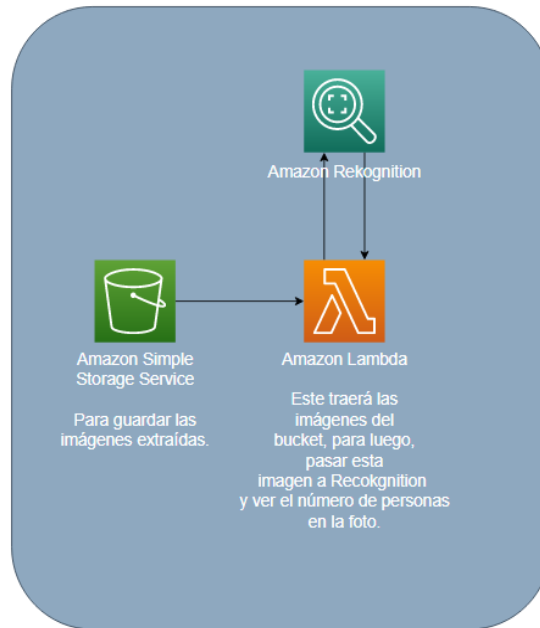


Figure 7: Prototipo en AWS

Para ello haremos uso del modelo presentado [Figura 7]. La idea de este es traer las imágenes de un bucket para luego procesarlas y dar un número de personas en la foto, con esto comprobar la eficiencia a través de unas fotos de prueba, asimilando la imagen de una Cámara de Transmilenio.

Una vez se prueba esto, también vamos a probar el uso concurrente de este pasándole varias imágenes al mismo tiempo al bucket, con esto saber que tanto se demora en subir cada imagen y el procesamiento del servidor lambda llegando varias imágenes.

9 Resultados

Para ver el repositorio de la implementación diríjase al siguiente link: <https://github.com/juanbaezl/ProyectoAREP>

9.1 Eficiencia

Tras pasarle 7 imágenes de un conglomerado de personas en Transmilenio, tanto dentro, como en las estaciones, logramos una eficiencia como la que




Figure 8: Gráfica de eficacia del modelo

Indice	Detectado	Real	Eficiencia	%Error
1	32	35	91%	9%
2	8	13	62%	38%
3	9	11	82%	18%
4	29	29	100%	0%
5	5	7	71%	29%
6	21	20	105%	-5%
7	4	5	80%	20%
Total	108	120	90%	10%

Figure 9: Tabla de Resultados

se ve en la Figura 8, esta es a partir de la tabla de la Figura 9. Tras desglosar este nos damos cuenta de que en ciertas imágenes donde es más difícil de identificar conseguimos un porcentaje de error mayor, sin embargo, en promedio logramos un porcentaje de eficacia del 90 por ciento.

9.2 Concurrencia

Tras analizar la cantidad de archivos subidos al mismo tiempo, tuvimos que se subieron 813.8KB al tiempo, los cuales se demoraron 6.36 segundos, lo que nos da una subida de 128KB por segundo.

En el servidor lambda, obtuvimos dada la gráfica que nos da Amazon [Figura 10] que el tiempo que más se demoró en procesar es al princi-




Figure 10: Gráfica de tiempo procesado por el servidor Lambda




Figure 11: Gráfica de tiempo procesado por el servidor Rekognition

pio donde recibe el evento del bucket, en el cual se demoró 1.2 segundos, esto debido a que esta primera parte hizo el procesamiento de 4 imágenes, mientras que en las otras las separó de forma más eficiente.

De la misma forma el servicio de Rekognition mantiene este comportamiento del servidor lambda como podemos ver en la Figura 11, aunque este obtiene unos resultados un poco más bajo.

10 Conclusiones

El uso de este modelo puede mejorar de forma significativa la movilidad para millones de personas en la ciudad, ayudando a una mejor circulación de Transmilenios con ayuda de la inteligencia artificial para optimizar la frecuencia de movimiento de rutas. Siendo más certero en la recolección de información de la cantidad de personas en cada estación, como de la amplitud de la información en el cálculo de la empresa Transmilenio.

Este modelo nos brinda un porcentaje de eficiencia del 90 por ciento usando un fotos desde ángulos poco favorables, es decir, desde los ángulos de las cámaras oficiales lograríamos un porcentaje más alto, por lo que, podemos concluir de forma favorable que esta solución podría ser imple-

mentada aumentando la efectividad de los cálculos a tiempo real.

11 Referencias

- [1] INRIX, “Bogota’s Scorecard Report”
<https://inrix.com/scorecard-city/?city=Bogotaindex=8>
- [2] Moovit, “Estadísticas de transporte público de Bogotá”
<https://moovitapp.com/insights/es-419>
- [3] Transmilenio, “Estadísticas de oferta y demanda del Sistema Integrado de Transporte Público SITP abril 2022”
<https://www.transmilenio.gov.co/publicaciones/152831/estadisticas-de-oferta-y-demanda-del-sistema-integrado-de-transporte-publico-sitp-abril-2022>
- [4] DataScientest, “Machine Learning: definición, funcionamiento, usos”
<https://datascientest.com/es/machine-learning-definicion-funcionamiento-usos>
- [5] IBERDROLA, “¿Somos conscientes de los retos y principales aplicaciones de la Inteligencia Artificial?”
<https://www.iberdrola.com/innovacion/que-es-inteligencia-artificial>
- [6] Oracle, “¿Qué es big data?”
<https://www.oracle.com/co/big-data/what-is-big-data/>
- [7] AWS Rekognition Video
<https://aws.amazon.com/es/rekognition/?nc=snloc=0>
- [8] AWS S3
shorturl.at/ksCJT
- [9] Amazon Kinesis Video Streams
<https://aws.amazon.com/es/kinesis/video-streams/>
- [10] AWS Lambda
shorturl.at/cwN29
- [11] El País, “Inteligencia artificial contra el atasco de todas las mañanas”
shorturl.at/hqty4

[12] Senstar. (2019). “Video Analytics Brochure”

[13] AWS. (2022). “Amazon Rekognition Guía para desarrolladores”